Instituto Federal de Educação, Ciência e Tecnologia de Goiás
Pró-Reitoria de Pesquisa e Pós-Graduação
Câmpus Goiânia
Mestrado Profissional em Tecnologia, Gestão e Sustentabilidade

Arthur Skowronski Passos

Monitoramento Remoto em Unidades de Conservação

Sistema de Inteligente na Identificação de Focos de Incêndio em Áreas de Unicades de Conservação

Goiânia, 2026.

INSTITUTO FEDERAL
Goiás

MINISTÉRIO DA EDUCAÇÃO
SECRETARIA DE EDUCAÇÃO PROFISSIONAL E TECNOLÓGICA
INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E TECNOLOGIA
PRÓ-REITORIA DE PESQUISA E PÓS-GRADUAÇÃO
SISTEMA INTEGRADO DE BIBLIOTECAS

TERMO DE AUTORIZAÇÃO PARA DISPONIBILIZAÇÃO NO REPOSITÓRIO DIGITAL DO IFG - ReDi IFG

Com base no disposto na Lei Federal nº 9.610/98, AUTORIZO o Instituto Federal de Educação, Ciência e Tecnologia de Goiás, a disponibilizar gratuitamente o documento no Repositório Digital (ReDi IFG), sem ressarcimento de direitos autorais, conforme permissão assinada abaixo, em formato digital para fins de leitura, download e impressão, a título de divulgação da produção técnico-científica no IFG.

Identificação da Produção Técnico-Científica

[ ] Tese	[ ] Artigo Científico
[X] Dissertação	[ ] Capítulo de Livro
[ ] Monografia – Especialização	[ ] Livro
[ ] TCC - Graduação	[ ] Trabalho Apresentado em Evento
[ ] Produto Técnico e Educacional - Tipo: _____	

Nome Completo do Autor: Fulano de Tal
Matrícula: XXXX
Título do Trabalho: XXXX

Autorização - Marque uma das opções

1. ( ) Autorizo disponibilizar meu trabalho no Repositório Digital do IFG (acesso aberto);
2. ( ) Autorizo disponibilizar meu trabalho no Repositório Digital do IFG somente após a data ___/___/_____ (Embargo);
3. ( ) Não autorizo disponibilizar meu trabalho no Repositório Digital do IFG (acesso restrito).

Ao indicar a opção **2 ou 3**, marque a justificativa:

( ) O documento está sujeito a registro de patente.
( ) O documento pode vir a ser publicado como livro, capítulo de livro ou artigo.
( ) Outra justificativa: _____

DECLARAÇÃO DE DISTRIBUIÇÃO NÃO-EXCLUSIVA

O/A referido/a autor/a declara que:

i. o documento é seu trabalho original, detém os direitos autorais da produção técnico-científica e não infringe os direitos de qualquer outra pessoa ou entidade;
ii. obteve autorização de quaisquer materiais inclusos no documento do qual não detém os direitos de autor/a, para conceder ao Instituto Federal de Educação, Ciência e Tecnologia de Goiás os direitos requeridos e que este material cujos direitos autorais são de terceiros, estão claramente identificados e reconhecidos no texto ou conteúdo do documento entregue;
iii. cumpriu quaisquer obrigações exigidas por contrato ou acordo, caso o documento entregue seja baseado em trabalho financiado ou apoiado por outra instituição que não o Instituto Federal de Educação, Ciência e Tecnologia de Goiás.

Goiânia - GO, XX / XX / 20XX
Local Data

Assinatura
_____
Assinatura do Autor e/ou Detentor dos Direitos Autorais

Instituto Federal de Educação, Ciência e Tecnologia de Goiás
Pró-Reitoria de Pesquisa e Pós-Graduação
Câmpus Goiânia
Mestrado Profissional em Tecnologia, Gestão e Sustentabilidade

Arthur Skowronski Passos

Monitoramento Remoto em Unidades de Conservação

Sistema de Inteligente na Identificação de Focos de Incêndio em Áreas de Unicades de Conservação

Programa de Pós-Graduação *Stricto Sensu* em Tecnologia, Gestão e Sustentabilidade do Instituto Federal de Educação, Ciência e Tecnologia de Goiás - Dissertação de Mestrado Profissional. Área de Concentração: Tecnologia de Sistemas de Produção Limpa. Linha de Pesquisa: Energias Renováveis.

Orientador: Prof. Carlos Roberto da Silveira Júnior

Goiânia, 2026.

Obs: Após defesa e correção, imprimir da capa ao sumário e entregar na biblioteca ou encaminhar email, solicitando a elaboração da Ficha Catalográfica
email para orientação de elaboração da FICHA CATALOGRÁFICA
bib.goiania@ifg.edu.br (biblioteca do IFG)

Modelo:

A654 Aproveitamento da água pluvial como uma alternativa para substituição da água tratada nas instalações da SANEAGO : uma proposta de gerenciamento ambiental para o distrito norte / Elcio Vânio de Oliveira et al. – Goiânia, 2009.
00f. : il.

Orientadora: Profª Drª Warde Antonieta da Fonseca-Zang
Co-orientador; Profª. Dr. Joachim Werner Zang.

Dissertação de Mestrado – Mestrado Profissional em Tecnologia de Processos Sustentáveis, Instituto Federal de Educação, Ciência e Tecnologia de Goiás.

1. Água pluvial – aproveitamento e alternativa 2. SANEAGO – tratamento de água – 4. Gerenciamento ambiental I. Fonseca-Zang, Warde Antonieta da (orientadora) II. Instituto Federal de Educação, Ciência e Tecnologia de Goiás, Mestrado em Tecnologia de Processos Sustentáveis.
1

CDD 363.700 817 3
2

Ficha catalográfica elaborada pelo responsável da Biblioteca Professor Jorge Félix de Souza, Instituto Federal de Educação, Ciência e Tecnologia de Goiás

Instituto Federal de Educação, Ciência e Tecnologia de Goiás
Pró-Reitoria de Pesquisa e Pós-Graduação
Câmpus Goiânia
Mestrado Profissional em Tecnologia, Gestão e Sustentabilidade

Arthur Skowronski Passos

Monitoramento Remoto em Unidades de Conservação

Sistema de Inteligente na Identificação de Focos de Incêndio em Áreas de Unicades de Conservação

Dissertação defendida no Programa de Pós-Graduação *Stricto Sensu* em Tecnologia, Gestão e Sustentabilidade do Instituto Federal de Educação, Ciência e Tecnologia de Goiás como requisito parcial para obtenção do título de Mestre em Tecnologia, Gestão e Sustentabilidade, aprovada em 11 deNovembro de 2026, pela Banca Examinadora constituída pelos professores:

Prof. Carlos Roberto da Silveira Júnior
Departamento IV - IFG / Câmpus Goiânia
Presidente da Banca

Dedicatória

Texto da dedicatória.

Agradecimentos

Texto de agradecimento.

Texto da Epígrafe

Autor,
Ano de nascimento-Ano de falecimento (se aplicável).

Resumo

Título: Monitoramento Remoto em Unidades de Conservação
Autor: Arthur Skowronski Passos
Orientador: Carlos Roberto da Silveira Júnior

A incidência persistente de queimadas representa uma grave ameaça socioambiental e econômica no Brasil, com especial gravidade no bioma Cerrado, que concentrou 68,5% das áreas queimadas no país em 2025, predominantemente em unidades de conservação. Embora existam soluções tecnológicas para o monitoramento remoto de focos de incêndio baseadas em inteligência artificial (IA), sensoriamento e visão computacional, os sistemas atuais enfrentam sérios gargalos operacionais: limitações de memória em dispositivos de borda (Edge AI), restrições de conectividade em regiões remotas desprovidas de cobertura móvel e, sobretudo, custos elevados de implantação e manutenção, que chegam a superar os R$ 8 milhões, para aplicações em maior escala, em alternativas comerciais baseadas em torres de monitoramento. Diante desse cenário, este trabalho propõe uma arquitetura de baixo custo e alta eficiência para a detecção precoce de incêndios florestais em Áreas de Preservação Ambiental. A solução desenvolvida integra uma câmera PTZ (Pan-Tilt-Zoom) para varredura e visualização da área monitorada, um computador de borda Nvidia Jetson Orin Nano para a execução local de modelos de visão computacional alimentados por um sistema autônomo fotovoltaico. Para contornar os desafios de comunicação, o sistema emprega uma topologia híbrida de conectividade que combina redes 4G e comunicação via rádio de longo alcance (LoRa). O ecossistema é articulado por um software dedicado ao envio automatizado de alertas e ao direcionamento tático de brigadas de combate.

Palavras–chave

Incêndios florestais; Visão computacional; Edge AI; LoRa; Nvidia Jetson Orin Nano; Monitoramento ambiental.

Abstract

Title: Remote Monitoring in Conservation Units
Author: Arthur Skowronski Passos
Advisor: Carlos Roberto da Silveira Júnior

The persistent incidence of wildfires poses a serious socio-environmental and economic threat in Brazil, particularly in the Cerrado biome, which accounted for 68.5% of the country's burned area in 2025, predominantly within conservation units. Although technological solutions for the remote monitoring of fire hotspots based on artificial intelligence (AI), sensing, and computer vision are available, current systems face major operational bottlenecks: memory limitations on edge devices (Edge AI), connectivity constraints in remote areas without mobile coverage, and, above all, high deployment and maintenance costs, which can exceed BRL 8 million for larger-scale applications using commercial alternatives based on monitoring towers. In response to this scenario, this study proposes a low-cost, high-efficiency architecture for the early detection of wildfires in Environmental Protection Areas. The proposed solution integrates a PTZ (Pan-Tilt-Zoom) camera to scan and provide visual coverage of the monitored area, and an NVIDIA Jetson Orin Nano edge computer to run computer vision models locally, powered by an autonomous photovoltaic system. To address communication challenges, the system employs a hybrid connectivity topology combining 4G networks and long-range radio communication (LoRa). The ecosystem is supported by dedicated software for the automated delivery of alerts and tactical dispatch of firefighting crews.

Keywords

Wildfires; Computer vision; Edge AI; LoRa; Nvidia Jetson Orin Nano; Environmental monitoring.

Lista de Figuras

Figura 1 – Arquitetura do modelo Faster R-CNN. O fluxo apresenta a extração de mapas de características por camadas convolucionais, seguida pela RPN, que atua direcionando a atenção da rede para a geração das propostas de regiões submetidas à camada de *RoI Pooling* e ao classificador final. 23
Figura 2 – Funcionamento da arquitetura da CNN YOLO. O sistema YOLO divide a imagem de entrada a partir de um grid de $S \times S$ e processa cada célula e prevê B *Bounding Boxes* para cada uma e C probabilidade de classes. 24
Figura 3 – Comparativo de eficiência entre as arquiteturas Faster R-CNN, YOLO e SSD. 24
Figura 4 – Dispositivo Raspberry Pi 1 Model B+, substituto do Model B anterior. 25
Figura 5 – Dispositivo NVIDIA Jetson TK1. 25
Figura 6 – Faixas do espectro eletromagnético infravermelho e seus respectivos intervalos de comprimento de onda (μm). 27
Figura 7 – Mapa do total anual de irradiação solar direta normal com destaque para regiões com maior potencial de aproveitamento da energia solar concentrada. 29
Figura 8 – Diagrama simplificado de um sistema Fotovoltaico (FV) *off-grid*. 30

Figura 9 – Fluxo das etapas metodológicas do sistema de monitoramento. 31
Figura 10 – Curva de eficiência (*trade-off* acurácia versus latência) comparando as variantes da família YOLO26 com arquiteturas anteriores de detecção de objetos no *benchmark* COCO. 32
Figura 11 – Kit de Desenvolvimento Nvidia Jetson Orin Nano. 37
Figura 12 – Câmera PTZ Intelbras VIP 5432 SD IR IA FT. 40

Lista de Tabelas

Tabela 1 – Comparativo das tecnologias de monitoramento de focos de incêndio. 19

Tabela 2 – Hiperparâmetros utilizados para treinamento do modelo YOLO26m. 34

Lista de Quadros

Lista de Algoritmos

Lista de Códigos de Programas

Lista de Símbolos

t	Tempo
L	Dimensão na direção x
H	Dimensão na direção y
ρ	Massa específica
μ	Viscosidade dinâmica
ν	Viscosidade cinemática

Sumário

1 Introdução 17

2 Referencial Teórico 22
2.1 Visão Computacional 22
2.2 Equipamentos de *Edge AI* 23
2.3 Câmeras de Monitoramento de Longo Alcance 26
2.4 Alimentação *Off-Grid* 28

3 Metodologia 31
3.1 Etapa I – Especificação e Aprimoramento do Modelo 32
3.1.1 Definição do Modelo 32
3.1.2 Definição do *Dataset* 33
3.1.3 *Fine Tuning* 34
3.2 Etapa II – Definição e Configuração do Hardware de *Edge AI* 36
3.2.1 Definição do Hardware 36
3.2.2 Configuração de Hardware 37
3.2.3 Integração da IA 37
3.3 Etapa III – Estabelecimento dos Meios de Comunicação 39
3.4 Etapa IV – Elaboração do Projeto Elétrico 39
3.4.1 Seleção de Equipamentos 39
3.4.2 Projeto Elétrico 41
3.4.3 Dimensionamento 41
3.5 Etapa V – Montagem do Protótipo em Campo 41
3.6 Etapa VI – Desenvolvimento da Interface Web 41

Referências 42

Apêndice A – Lista de palavras-chave em português para o pacote algorithm2e 47

Anexo A – Exemplo de anexo 49

CAPÍTULO 1

Introdução

O Cerrado é o segundo maior bioma brasileiro, cobrindo cerca de 25% do território nacional (2,03 milhões de km²) e, devido a essa extensão, apresenta diversas fitofisionomias (Guarlado, 2023) que contribuem para a biodiversidade desse ecossistema. O bioma é conhecido como a "caixa d'água do Brasil" por abrigar as bacias dos rios São Francisco, Tocantins-Araguaia e Paraná, sendo as duas primeiras componentes essenciais das principais regiões hidrográficas do país (Agência Nacional de Águas Brasil, 2015), além de ser reconhecida como o segundo maior bioma brasileiro e a savana mais rica do mundo em biodiversidade com mais de 10.000 espécies de plantas e 1.200 espécies de animais (IBGE – Instituto Brasileiro de Geografia e Estatística, 2009).

Paralelamente, o bioma abriga 211 Unidades de Conservação (UCs) com dados registrados, totalizando uma área protegida de 22.616.242,33 hectares (ha). Dentre essas unidades, destacam-se 55 Parques Estaduais (PEs), 16 Parques Nacionais (PNs) e 56 Áreas de Proteção Ambiental (APAs), consoante os dados disponibilizados pelo Instituto Socioambiental (Instituto Socioambiental (ISA), s.d.).

Contudo, a despeito de sua relevância, o Cerrado é o bioma mais atingido pelo desmatamento no país, concentrando mais da metade (55%) de toda a área desmatada do território nacional (MapBiomas, 2026a). Somada a esse cenário, a constante incidência de queimadas tem agravado a degradação do bioma, impondo severas perdas à sua biodiversidade e aos serviços ecossistêmicos.

Apesar do ano de 2025 ter apresentado uma baixa na área total queimada globalmente (Burton *et al.*, 2026), o Cerrado permaneceu como ponto crítico: cerca de 8,7 milhões de hectares queimados, representando 69% das queimadas totais, de acordo com dados de MapBiomas (2026b). Os prejuízos causados por essa degradação ambiental afetam diretamente os lagos e rios do Cerrado ao comprometer a cobertura de água, a qual, em 2022, sofreu uma redução em 66% das regiões hidrográficas do bioma em áreas de preservação (Guarlado, 2023). Além disso, dados históricos apontam maior concentração dessas queimadas em áreas de conservação, com uma densidade de 37,1 focos/1.000km² – correspondente à 62,91% do total

registrado – em comparação aos 45,3 focos/1.000km² observados nas demais áreas (Vasconcelos; Freitas; Lazzarini, 2019).

Contudo, os impactos transcendem a esfera ambiental: em 2024, as perdas nas áreas de produção agropecuária atingiram R$ 1,5 bilhão, além de o cenário ter provocado o aumento das internações por problemas respiratórios e a suspensão de aulas em diversas escolas (Versiane, 2025).

Com o objetivo de contornar esse problema, diversas empresas e instituições desenvolvem pesquisas e tecnologias capazes de detectar focos de incêndio, seja via satélite, torres de monitoramento, drones e equipamento de borda para processamento de dados em campo. Dentre as soluções analisadas, as torres de monitoramento destacam-se, diante o cenário específico, pelo menor tempo de resposta, maior precisão e menor custo operacional. Essa superioridade evidencia-se na comparação das características dos sistemas apresentados na Tabela 1, na qual essas estruturas combinam tempo de resposta imediato a um baixo custo operacional contínuo.

Estudos focados na viabilidade e eficácia das tecnologias de sensoriamento remoto óptico aprofundam as limitações operacionais de cada plataforma de aquisição. Conforme discutido na revisão sistemática de Barmpoutis *et al.* (2020), as abordagens baseadas em plataformas orbitais (satélites) enfrentam um dilema intrínseco de compromisso (*trade-off*) espaço-temporal: sistemas dotados de alta taxa de amostragem temporal operam sob resolução espacial excessivamente ampla, ao passo que sensores de maior detalhamento em solo sofrem com longos intervalos de revisita orbital. Essa discrepância espacial e temporal restringe o emprego prático de satélites no combate tático imediato, uma vez que a latência na disponibilização das imagens compromete o fornecimento de alertas precoces em tempo real frente a eventos de rápida propagação.

Alternativamente, os sistemas aéreos – compreendendo aeronaves tripuladas e veículos aéreos não tripulados (VANTs/drones) – conseguem mitigar essas restrições ao sobrevoar áreas de risco sob demanda e aproximar sensores visuais e infravermelhos da superfície. No entanto, Barmpoutis *et al.* (2020) salientam que essas plataformas apresentam autonomia energética estritamente limitada, exigindo missões pontuais programadas, operadores dedicados e condições atmosféricas favoráveis para navegação segura, o que inviabiliza uma vigilância contínua e autônoma em regime integral (24/7).

Em relação às torres de monitoramento fixo, Barmpoutis *et al.* (2020) destacam que essa abordagem se consolida como a mais vantajosa para a detecção de incêndios em seus estágios iniciais. Instaladas em pontos topográficos estrategicamente elevados e equipadas com sensores ópticos ou termográficos contínuos, as estações terrestres oferecem alta resolução de solo associada à aquisição instantâ-

Tabela 1 – *Comparativo das tecnologias de monitoramento de focos de incêndio.*

Tecnologia	Tempo Resposta	Cobertura de Área	Precisão Espacial	Custo Operac.	Autonomi 24/7	Indep. de Rede
Drones/VANTs	+	○	+	○	−	○
Torres	○	+	+	+	○	○
Satélites	+	+	−	○	○	−

Legenda: (+) Alto/favorável; (○) Moderado; (−) Crítico/limitado.

Fonte: Autoral (2026)..

nea de dados, dispensando intervalos de revisita orbital ou recargas operacionais constantes. Ademais, a integração direta dessas estruturas fixas com módulos de computação em borda e redes de comunicação sem fio permite o processamento autônomo dos fluxos de vídeo no próprio local da torre, assegurando a identificação de plumas de fumaça incipientes e o disparo imediato de alertas às equipes de resposta antes que o fogo atinja proporções incontroláveis.

Nesse sentido, com o propósito de se aprofundar nas soluções baseadas no uso de torres de monitoramento, diversos estudos e técnicas para detecção e localização desses focos de incêndio têm sido desenvolvidas. Entre eles, a pesquisa de Khalifeh *et al.* (2022) empregou uma abordagem condicional fundamentada em dois sistemas específicos de detecção: *Artificial Neural Network* (ANN) – sensores que captam informações de ambiente (temperatura, umidade, pressão atmosférica/barométrica, e compostos orgânicos voláteis (COVs)), das quais são processadas por uma Rede Neural Artificial (RNA) simples que identifica padrões e classifica essas informações – e *Convolutional Neural Network* (CNN) – abordagem de Visão Computacional (VC) utilizando uma Rede Neural Convolucional (RNC) para classificar a imagem e verificar a presença de incêndio ou fumaça. Porém, utilizando dispositivos de borda para processamento desses dados em campo, tiveram dificuldades em implementar modelos de eficácia superior diante da limitação de espaço na memória do equipamento.

De outra forma, Matamoros, Montalván e Martínez (2025) avançaram no desenvolvimento da VC do sistema, explorando diversas abordagens. O sistema de VC final apresentou uma metodologia híbrida entre processamento de imagem tradicional e Inteligência Artificial (IA). Além disso, implementaram uma lógica de

decisão dupla, da qual os sensores e a RNC devem detectar o fogo com um certo valor de confiança e envio automático de mensagem via Telegram.

Porém, os desafios de implementação dessa abordagem não se limitam às tecnologias de sensoriamento óptico e detecção de chamas. O monitoramento contínuo em áreas de preservação ambiental enfrenta severas barreiras de infraestrutura de conectividade, sobretudo devido à cobertura escassa ou inexistente de redes celulares comerciais (3G/4G). Como alternativa para contornar essa limitação em relevo florestal denso, Zhao *et al.* (2023) propuseram uma arquitetura de comunicação híbrida fundamentada em redes *Low-Power Wide-Area Network* (LPWAN) . A solução emprega sensores com tecnologia celular de banda estreita (NB-IoT) nas poucas localidades dotadas de sinal de operadora, integrando-os a uma malha de rádio frequência de longo alcance (LoRa) nas zonas sem cobertura. Diante da intensa atenuação eletromagnética provocada pela folhagem e pelo relevo montanhoso, os autores implementaram um algoritmo de roteamento por múltiplos saltos (*multi-hop*) com repetidoras intermediárias espaçadas estrategicamente entre 400 m e 1 km. Essa topologia permitiu retransmitir a telemetria ambiental com latência média de 10 segundos até um *gateway* centralizado conectado à rede móvel, viabilizando o fluxo ininterrupto de dados rumo aos servidores em nuvem.

Algumas empresas já usufruem desses resultados de pesquisas no desenvolvimento de produtos de monitoramento remoto. A Startup Agteck i2dt construiu um sistema que contém sensores de ambiente capazes de detectar a presença de incêndios e enviar a localização da posição do dispositivo com um alerta através de uma LoRa *Mesh* (Centro de Pesquisa e Desenvolvimento em Telecomunicações (CPQD), 2025). Na mesma linha, a AgroRobotics realiza detecção de focos de incêndio utilizando VC em computadores domésticos através de uma câmera estacionária instalada em uma região estratégica e realizando a comunicação via internet 3G (Agro Robotics, 2022).

Entre as soluções comerciais disponíveis, destaca-se a plataforma desenvolvida pela *startup* Umgrauemeio, denominada Pantera. O sistema baseia-se na implantação de uma infraestrutura de torres de monitoramento equipadas com câmeras integradas a algoritmos de inteligência artificial, posicionadas estrategicamente ao redor da área de interesse. Os dados coletados são transmitidos em tempo real a uma central de processamento encarregada de gerar alertas automatizados e orientações operacionais para o combate a incêndios. Contudo, a adoção dessa tecnologia exige expressivo aporte financeiro: a implementação em áreas de preservação ambiental pode superar os R$ 8 milhões (JN Fogo – Câmeras Amolar, 2023). Em termos de custos unitários, estima-se que a instalação de cada torre demande cerca de R$ 60 mil, acrescida de uma taxa de manutenção mensal de aproximadamente R$ 10 mil

por dispositivo (Fantin, 2025).

Diante desse cenário, esta pesquisa visa mitigar os principais gargalos dos sistemas de monitoramento remoto convencionais, sobretudo o alto custo de implementação e a limitação de comunicação em áreas remotas, propondo uma arquitetura de baixo custo e alta eficiência voltada a Áreas de Preservação Ambiental. O objetivo principal envolve o desenvolvimento de um sistema de monitoramento remoto utilizando equipamento de borda para processamento de dados em tempo real, alimentação *off-grid* e, principalmente, uma rede de comunicação eficaz para áreas remotas.

De forma mais detalhada, a solução explora a integração do computador de borda Nvidia Jetson Orin Nano para a execução local de modelos de Visão Computacional, utilização de câmera *Pan-Tilt-Zoom* (PTZ) e um sistema de alimentação fotovoltaico autônomo. A conectividade e a otimização da transmissão de dados serão viabilizadas ao averiguar a topologia híbrida que combina redes 4G e comunicação por rádio frequência via tecnologia LoRa. Por fim, o ecossistema será complementado por um software dedicado ao envio de alertas e à orientação operacional das brigadas de combate, priorizando eficácia na detecção precoce de incêndios a um custo significativamente menor.

CAPÍTULO 2

Referencial Teórico

Para viabilizar uma arquitetura autônoma e de baixo custo voltada à detecção precoce de focos de incêndio em áreas remotas de preservação utilizando modelos de Inteligência Artificial, torna-se necessário discorrer sobre as diferentes tecnologias e técnicas que serão utilizadas para o desenvolvimento do sistema.

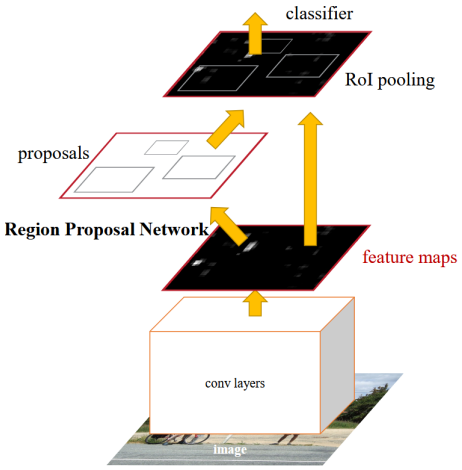
2.1 Visão Computacional

Modelos de IA aplicados à Visão Computacional são amplamente empregados no reconhecimento de padrões complexos em imagens. No âmbito dos modelos baseados em CNNs, um avanço decisivo ocorreu com o desenvolvimento da arquitetura Faster R-CNN (Figura 1) por Ren *et al.* (2015), que introduziu a *Region Proposal Network* (RPN), integrando a geração de propostas de regiões ao treinamento ponta a ponta e otimizando o tempo de processamento, atingindo valores de 0,5 quadros por segundo (FPS).

Posteriormente, Redmon *et al.* (2016) propuseram o YOLOv1 (*You Only Look Once*). A abordagem ilustrada pela Figura 2 redefiniu a tarefa ao estruturar a imagem em uma grade regular e formular a predição das coordenadas das caixas delimitadoras (*Bounding Boxes*) e das probabilidades de classe como um problema único de regressão direta. Essa arquitetura de CNN foi capaz de atingir o marco de 45 FPS processados em tempo real, embora apresentasse limitações na localização de objetos pequenos e agrupados.

Liu *et al.* (2016) introduziu uma solução alternativa denominada *Single Shot Multibox Detector* (SSD). Enquanto o YOLO utilizava apenas o último mapa de características e dependia de camadas densas no topo da rede, o SSD eliminou as camadas totalmente conectadas e formulou uma estrutura puramente convolucional. Esse modelo, por sua vez, contornava o gargalo apresentado pelo modelo YOLOv1 em detectar pequenas *Bounding Boxes*, sendo necessário 1,6 giga de operações de ponto flutuante (GFLOPS). Na Figura 3 é apresentada uma comparação direta

Figura 1 – *Arquitetura do modelo Faster R-CNN. O fluxo apresenta a extração de mapas de características por camadas convolucionais, seguida pela RPN, que atua direcionando a atenção da rede para a geração das propostas de regiões submetidas à camada de RoI Pooling e ao classificador final.*



Fonte: Fonte: Ren *et al.* (2015).

entre as arquiteturas desenvolvidas, além de trazer o comparativo de eficiência dos modelos.

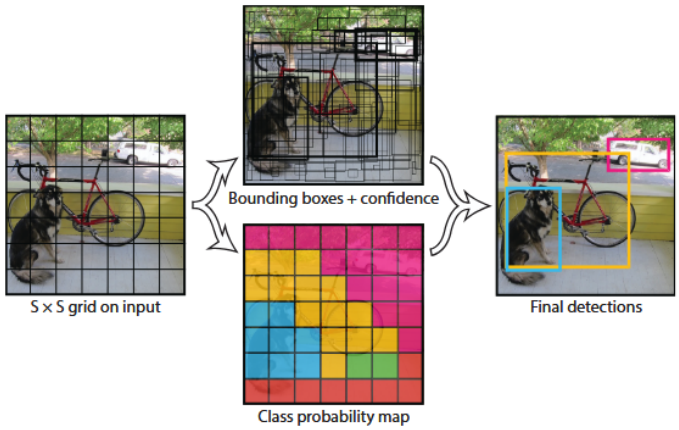
Diante do aumento da demanda por processamento em dispositivos de borda, algumas restrições quanto à complexidade computacional dos modelos CNNs foram impostas. Nesse cenário, Howard *et al.* (2017) junto à equipe da Google apresentaram as Convoluções Separáveis em Profundidade (*Depthwise Separable Convolutions*) através do modelo MobileNet proposto. A nova estrutura proposta do modelo CNN reduziu em aproximadamente 8 a 9 vezes os parâmetros e as operações para 1,13 kFLOPs.

O desenvolvimento de arquiteturas baseadas em CNNs evoluiu substancialmente, impulsionando o surgimento de diversos modelos voltados para *Edge AI*. Essas redes exploram diferentes abordagens estruturais e técnicas de compressão computacional para maximizar a eficiência energética e a velocidade de inferência. Tais tecnologias deverão ser analisadas em relação à eficácia e custo computacional a fim de selecionar o modelo ideal para realizar a identificação e a classificação de focos de incêndio.

2.2 Equipamentos de *Edge AI*

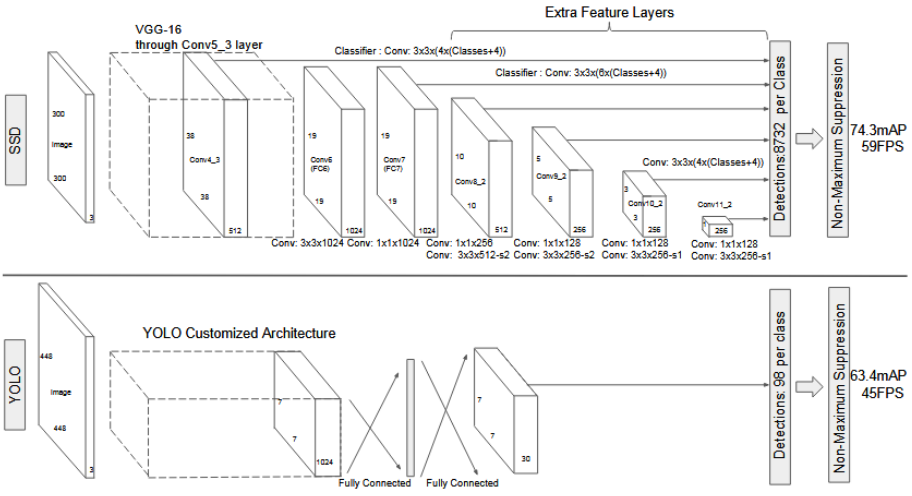
O avanço substancial do aprendizado profundo, impulsionado em 2012 pela vitória da AlexNet (Krizhevsky; Sutskever; Hinton, 2012) no desafio da *ImageNet*,

Figura 2 – *Funcionamento da arquitetura da CNN YOLO. O sistema YOLO divide a imagem de entrada a partir de um grid de $S \times S$ e processa cada célula e prevê B Bounding Boxes para cada uma e C probabilidade de classes.*



Fonte: Fonte: Ren *et al.* (2015).

Figura 3 – *Comparativo de eficiência entre as arquiteturas Faster R-CNN, YOLO e SSD.*



Fonte: Liu *et al.* (2016).

estabeleceu um ponto de inflexão na área de visão computacional. Embora já existissem plataformas embarcadas capazes de processar algoritmos clássicos de processamento de imagem, como a Raspberry Pi 1 Model B (Raspberry Pi Foundation, s.d.) apresentado na Figura 4, tais dispositivos apresentavam severas limitações computacionais para suprir a elevada demanda de FLOPs exigida pelas redes convolucionais profundas.

Figura 4 – *Dispositivo Raspberry Pi 1 Model B+, substituto do Model B anterior.*



Fonte: Fonte: Adaptado de Raspberry Pi Foundation (s.d.)..

Para mitigar esse gargalo, a indústria de semicondutores voltou seus esforços ao desenvolvimento de arquiteturas de hardware voltadas à aceleração dessas cargas de trabalho. Como marco dessa transição, a NVIDIA introduziu em 2014 a placa Jetson TK1 (Harrys, 2014), que incorporou núcleos CUDA ao ecossistema de sistemas embarcados. Essa convergência viabilizou a consolidação de dispositivos modernos de *Edge AI*, garantindo capacidade de processamento local, redução crítica de latência e autonomia operacional para instalações remotas ou sujeitas a restrições de conectividade de rede.

Figura 5 – *Dispositivo NVIDIA Jetson TK1.*



Fonte: Fonte: Harrys (2014).

Nos anos subsequentes, o mercado testemunhou uma proliferação de plataformas orientadas a ampliar a eficiência no processamento de tais algoritmos. Enquanto a NVIDIA expandia sua linha com arquiteturas gráficas progressivamente mais potentes, outros fabricantes, a exemplo da Intel, investiram no projeto de unidades de aceleração dedicadas. Nesse contexto, a Intel anunciou em 2017 a VPU Movidius Myriad X, incorporando o *Neural Compute Engine* (NCE) – um bloco de hardware de função fixa projetado para a aceleração de operações convolucionais que elevou o rendimento do chip para 1 trilhão de operações por segundo (TOPS) (Intel Corporation, 2018).

Em contrapartida, no ano de 2019, a Google estabeleceu um marco no setor ao introduzir a Edge TPU. O circuito integrado baseava-se em uma matriz sistólica de multiplicação e acumulação (*Multiply-Accumulate* – MAC) otimizada estritamente para o *runtime* TensorFlow Lite com tensores quantizados em INT8, alcançando 4 TOPS com consumo de apenas 2 W. Desde então, essas tecnologias vêm sendo continuamente aprimoradas por fabricantes consolidados e novos concorrentes, mantendo a maximização da eficiência energética e do rendimento computacional no centro do desenvolvimento de hardware para *Edge AI*.

2.3 Câmeras de Monitoramento de Longo Alcance

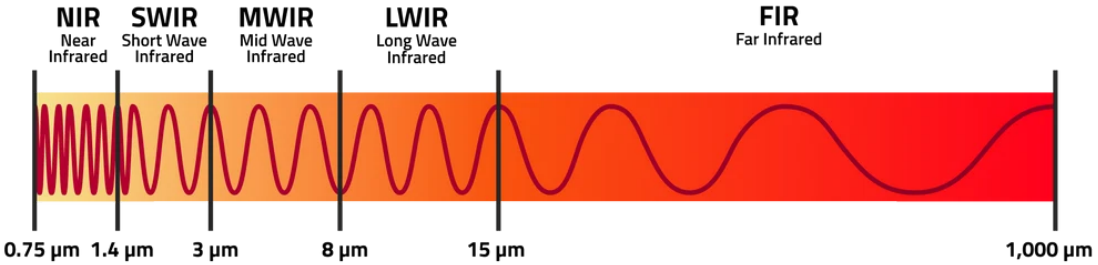
As câmeras de monitoramento modernas integram recursos ópticos e computacionais projetados para maximizar a resolução, o alcance e a fidelidade visual das capturas, além de apresentar robustez mecânica contra intempéries. Complementarmente, esses dispositivos incorporam funcionalidades analíticas embarcadas, viabilizando a identificação e a classificação automática de eventos, transeuntes, animais e objetos de interesse na cena vigiada.

Em termos de mobilidade física, as câmeras PTZ (*Pan-Tilt-Zoom*) diferenciam-se por integrar eixos motorizados para varredura horizontal (*pan*) e ajuste vertical (*tilt*), aliados a lentes de zoom óptico ajustável. Essa configuração é essencial para o monitoramento florestal e a detecção de incêndios, pois permite a cobertura contínua de grandes extensões de área e a inspeção detalhada de fumaça a longas distâncias.

Contudo, tais recursos mecânicos e ópticos não bastam para mitigar todos os desafios inerentes à detecção de queimadas. As limitações do sensoriamento restrito ao espectro da luz visível permanecem como um obstáculo crítico, decorrentes tanto da ausência de irradiância solar durante o período noturno quanto de

atenuações atmosféricas severas provocadas por nevoeiros ou densas colunas de fumaça. Para mitigar esses entraves, soluções modernas de sensoriamento empregam sensores no espectro infravermelho (*Infrared* – IR), permitindo a detecção térmica contínua independentemente da iluminação visível (Driggers *et al.*, 2022). Conforme apresentado na Figura 6, a radiação infravermelha abrange cinco regiões espectrais: o infravermelho próximo (NIR), o infravermelho de ondas curtas (SWIR), o infravermelho de ondas médias (MWIR), o infravermelho de ondas longas (LWIR) e o infravermelho distante (FIR).

Figura 6 – *Faixas do espectro eletromagnético infravermelho e seus respectivos intervalos de comprimento de onda (µm).*



Fonte: Fonte: Advexure (2023).

No contexto do monitoramento e detecção precoce de incêndios em áreas de preservação, cada banda do espectro infravermelho desempenha funções analíticas distintas conforme as propriedades físicas de emissão e propagação (Driggers *et al.*, 2022):

NIR (0,75 – 1,4 µm): Opera predominantemente pela reflexão de luz (solar ou artificial de LEDs IR), viabilizando a vigilância noturna convencional e a avaliação da reflectância foliar para monitorar o ressecamento da biomassa florestal, embora ainda sofra bloqueio visual frente a fumaças espessas.

SWIR (1,4 – 3 µm): Apresenta menor dispersão por aerossóis (espalhamento de Rayleigh e Mie), permitindo penetrar névoas e fumaças dispersas. Capta anomalias térmicas severas (>800 K) sem a saturação precoce comum aos sensores do espectro visível.

MWIR (3 – 8 µm): Coincide com o pico espectral de irradiância das frentes de combustão ativa (600 K a 1.200 K) ditado pela Lei de Wien. É a banda mais indicada para discriminar chamas ativas e identificar gases quentes oriundos da combustão.

LWIR (8 – 15 µm): Coincide com a curva radiativa da superfície terrestre e da vegetação à temperatura ambiente ($\approx$300 K), possibilitando operação passiva

24/7 sem necessidade de iluminação externa, transpassando fumaça densa e revelando brasas subterrâneas, troncos incandescentes e rescaldo.

FIR ($15 - 1.000\,\mu$m): Correspondente a emissões térmicas de corpos extremamente frios, apresenta forte atenuação atmosférica na baixa troposfera devido à absorção molecular, o que limita seu emprego em câmeras ópticas de vigilância terrestre, restringindo seu uso majoritariamente a estudos climatológicos e astronômicos.

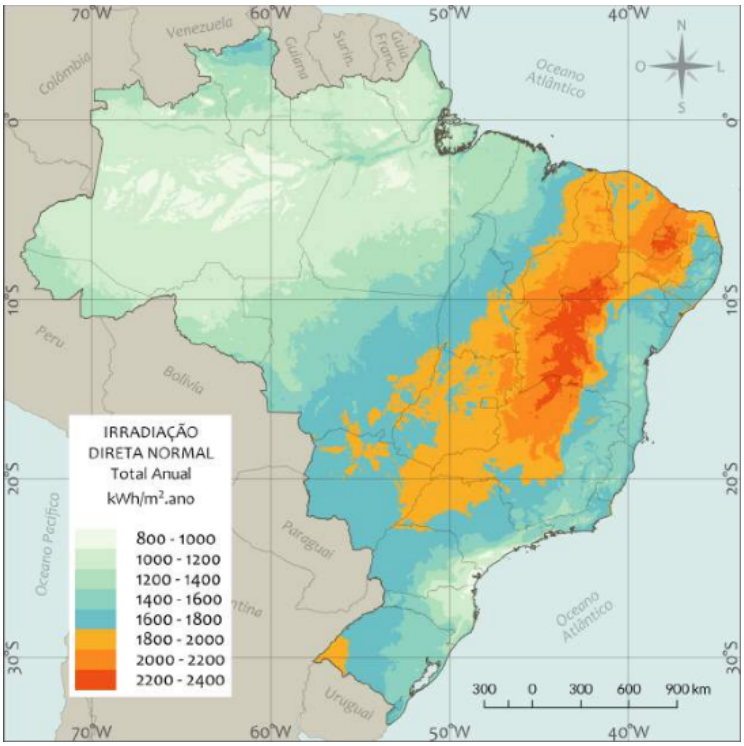
No entanto, a integração dessas faixas do infravermelho em câmeras de monitoramento esbarra em restrições técnicas que aumentam o custo da tecnologia. A necessidade de materiais ópticos especializados (como lentes de germânio, transparentes ao infravermelho médio e longo) somada à suscetibilidade dos detectores térmicos ao ruído – exigindo módulos de dissipação térmica ou rotinas constantes de recalibração radiométrica – eleva consideravelmente o custo de aquisição e implantação desses dispositivos em campo.

2.4 Alimentação *Off-Grid*

Com o intuito de garantir a operação ininterrupta do sistema de forma autônoma e sem necessidade de intervenção humana direta, a infraestrutura deve contar com um subsistema de alimentação energética sustentável e autossuficiente. Ao avaliar as alternativas disponíveis para a implementação desse subsistema em regiões isoladas, a geração solar fotovoltaica consolida-se como a abordagem mais viável. Essa escolha fundamenta-se na elevada disponibilidade de irradiância solar típica do bioma Cerrado, de acordo com a Figura 7, aliada à ausência de componentes móveis na conversão de energia, o que reduz substancialmente a demanda de manutenção mecânica, mitiga o risco de falhas em campo e oferece uma relação custo-benefício superior quando associada a um banco de baterias dimensionado para suprir períodos de baixa insolação ou operação noturna contínua.

A implementação prática dessa estrutura fotovoltaica autônoma demanda um arranjo integrado por módulos de geração, controle, armazenamento e conversão de energia. Nesse contexto, o controlador de carga atua na regulação da tensão e da corrente provenientes dos painéis fotovoltaicos, gerenciando os ciclos de recarga e prevenindo sobrecargas ou descargas profundas no acumulador. O armazenamento energético apoia-se em um banco de baterias estacionárias de ciclo profundo, responsável por assegurar o suprimento ininterrupto ao nó de borda durante a noite ou sob períodos de nebulosidade prolongada. Para o atendimento às cargas, o circuito dispõe de uma saída em corrente contínua dedicada à alimentação de barramentos lógicos regulados, enquanto um inversor *off-grid* de onda senoidal

Figura 7 – *Mapa do total anual de irradiação solar direta normal com destaque para regiões com maior potencial de aproveitamento da energia solar concentrada.*



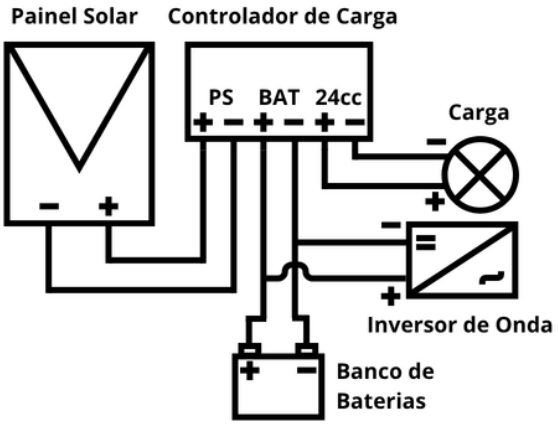
Fonte: Fonte: Pereira *et al.* (2017).

pura é incorporado para suprir os subsistemas que operam sob corrente alternada, garantindo estabilidade de tensão e proteção contra transientes para o conjunto embarcado.

Para suprir demandas de carga em corrente contínua (CC) e corrente alternada (CA) de forma ininterrupta, a literatura recomenda a adoção de uma topologia de barramento CC desacoplado, a qual otimiza a eficiência e a segurança operacional do sistema (Pinho; Galdino, 2014). A Figura 8 ilustra o arranjo eletroeletrônico empregado, destacando a segregação dos barramentos CC e CA, bem como o posicionamento dos disjuntores de proteção dedicados ao seccionamento das cargas de 24 V (CC) e do estágio de conversão para as cargas de 220 V / 60 Hz (CA).

Sendo assim, o capítulo a seguir apresenta o detalhamento metodológico empregado no dimensionamento, na integração e na validação do sistema proposto.

Figura 8 – *Diagrama simplificado de um sistema Fotovoltaico (FV) off-grid.*



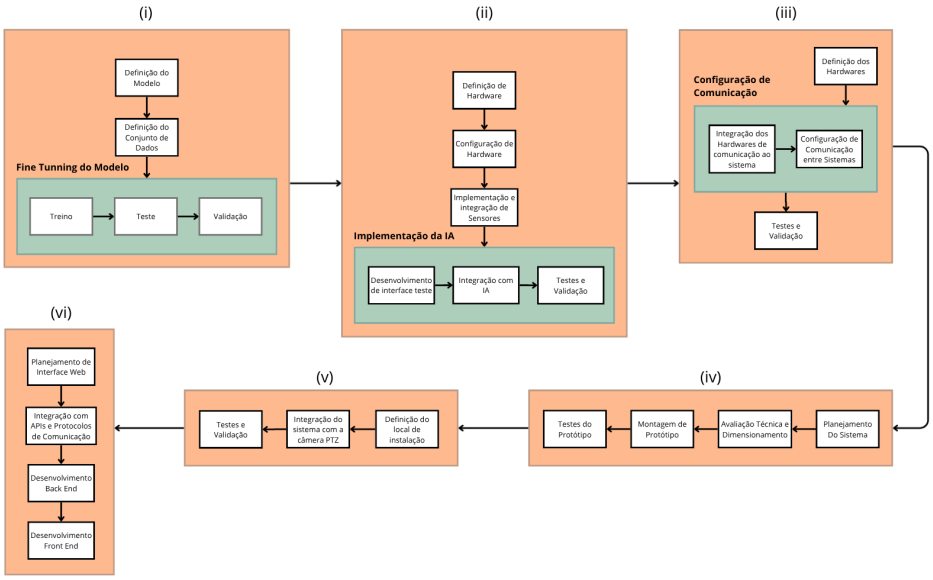
Fonte: Fonte: Autoral..

CAPÍTULO 3

Metodologia

Este capítulo apresenta a abordagem metodológica empregada no desenvolvimento e na validação do sistema de monitoramento remoto, caracterizada como uma pesquisa experimental aplicada. A execução do trabalho foi estruturada em seis etapas fundamentais: (I) especificação e aprimoramento do modelo de inteligência artificial; (II) definição e configuração do *hardware* para *Edge AI*; (III) elaboração do projeto elétrico e de alimentação do sistema; (IV) estabelecimento do meio de comunicação de dados em áreas remotas; (V) montagem do protótipo em campo para testes de validação; e (VI) desenvolvimento de uma aplicação web de monitoramento, controle e recebimento de alertas. Conforme ilustrado no fluxo da Figura 9, cada uma dessas etapas desdobra-se em procedimentos específicos que asseguram o rigor e a reprodutibilidade da pesquisa.

Figura 9 – *Fluxo das etapas metodológicas do sistema de monitoramento.*



Fonte: Fonte: Autoral..

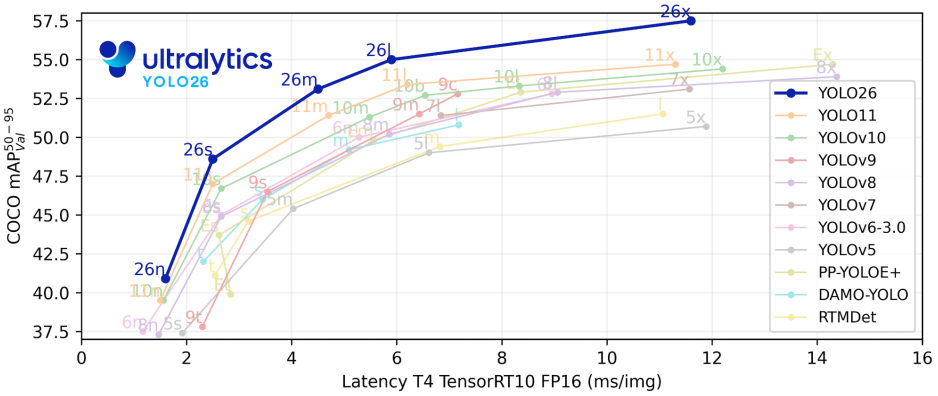
3.1 Etapa I – Especificação e Aprimoramento do Modelo

A seguinte etapa é composta por três processos: Definição do Modelo; Definição do Conjunto de Dados; e *Fine Tuning* do modelo que se divide em três subprocessos denominados Treino, Teste e Validação. Esse conjunto de tarefas contribuem para a construção de um modelo de CNN capaz de identificar focos de incêndio com um certo nível de eficácia determinado por um conjunto de métricas a serem avaliadas.

3.1.1 Definição do Modelo

Analisando as diferentes arquiteturas existentes apresentadas na fundamentação teórica e os modelos disponíveis no mercado, a variante intermediária da família YOLO26 (Jocher *et al.*, 2026) estabelece um equilíbrio estratégico entre capacidade representacional e custo computacional, viabilizando inferências em tempo real sem sobrecarregar os recursos limitados da plataforma de borda. Essa superioridade na fronteira de eficiência é respaldada pelos resultados comparativos apresentados na Figura 10, na qual a família YOLO26 supera as gerações anteriores na relação de compromisso entre acurácia média ($\overline{\text{AP}}$) e latência de inferência em precisão de meia precisão (FP16).

Figura 10 – *Curva de eficiência (trade-off acurácia versus latência) comparando as variantes da família YOLO26 com arquiteturas anteriores de detecção de objetos no benchmark COCO.*



Fonte: Jocher *et al.* (2026)..

Especificamente, a variante YOLO26m sendo executada pelo dispositivo NVIDIA Tesla T4 GPU, alcança aproximadamente 53,1% de mAP sob um tempo de execução de apenas 4,5 ms por imagem e atingindo até 194,4 GFLOPs, supe-

rando o desempenho de detecção de modelos de maior porte de gerações legadas (como YOLOv5x e YOLOv7) enquanto preserva margem temporal e computacional suficiente para processamento contínuo em nós embarcados.

As métricas apresentadas estão relacionadas ao *dataset* COCO (Lin *et al.*, 2014), que possui 80 classes diferentes em imagens anotadas, servindo como *benchmark* para a avaliação de modelos de detecção de objetos e segmentação de instâncias. Para o escopo deste trabalho, o modelo foi delimitado à detecção de duas classes de interesse: fogo e fumaça. Essa especificação busca não apenas identificar incêndios em estágios avançados de propagação, mas também viabilizar a detecção precoce por meio da identificação de fumaça em fases iniciais. Além disso, a restrição do vocabulário a essas duas classes visa otimizar a capacidade de generalização do modelo e aumentar a precisão na extração de características específicas para esses alvos.

Em relação aos diferenciais arquitetônicos do modelo, a principal inovação reside na adoção de um paradigma de treinamento com cabeçote duplo (*dual-head architecture*), que combina uma ramificação um-para-muitos (*one-to-many*) rica em supervisão semântica durante a fase de treino com uma ramificação um-para-um (*one-to-one*) voltada ao descarte do pós-processamento por Supressão de Não-Máximos (*Non-Maximum Suppression* – NMS) na etapa de *deployment*. No *backbone* e *neck*, a rede substitui estruturas anteriores por blocos C3k2 otimizados e módulos de atenção espacial e de escala (S2A/PSA), aliando a extração eficiente de características à redução de operações redundantes. Adicionalmente, o treinamento emprega o otimizador MuSGD, uma combinação do algoritmo Muon para a atualização de matrizes de peso bidimensionais com o SGD convencional, o que estabiliza o aprendizado profundo e melhora a eficiência de convergência do modelo.

Com o intuito de adaptar essa arquitetura pré-treinada às especificidades do problema abordado, o modelo é submetido a um processo de ajuste fino (*fine-tuning*), cujos parâmetros, hiperparâmetros e procedimentos experimentais são detalhados em outra seção do capítulo.

3.1.2 Definição do *Dataset*

Conforme a metodologia apresentada no relatório de Silva *et al.* (2026), que descreve todo o processo de desenvolvimento do modelo de VC de detecção de foco de incêndio, o *dataset* do presente estudo foi constituído pelas imagens de *Forest Fire, Smoke and Non-Fire Image Dataset* (Minha, 2023), referido como FFSNDataset. A base é composta, em seu conjunto de treinamento, por 10.800 imagens positivas para fogo, 10.800 imagens positivas para fumaça e 10.800 imagens negativas apresentando uma distribuição equitativa das amostras no conjunto de treino, porém não anotadas.

3.1.3 *Fine Tuning*

Diante o pré-processamento do modelo YOLO26m utilizando o *dataset* COCO, será aplicado um ajuste fino (*fine tuning*) utilizando o *dataset* indicado anteriormente com, no total, 23.495 imagens, sendo 7.325 anotadas manualmente com o auxílio da plataforma *Computer Vision Annotation Tool* (CVAT) distribuídas pelo *split* 70:20:10. Devido a diversidade de cenários e tipos de incêndios dispostos nas imagens do FFSNDataset, que são relevantes para aplicação dessa detecção no bioma do Cerrado, favoreceu a generalização do modelo.

De acordo com Silva *et al.* (2026), o treinamento e a validação do modelo foi conduzido na estação de trabalho Dell Precision Tower 5810, equipada com processador Intel Xeon E5-1650 v3 (6 núcleos físicos e 12 processadores lógicos), placa gráfica NVIDIA RTX A4500 e 128 GB de memória RAM DDR4, operando sob o sistema Microsoft Windows 11 Pro. Esse *hardware* fornece um ambiente estável para a execução de algoritmos de VC baseados na arquitetura YOLO. Os valores dos hiperparâmetros empregados no treinamento são apresentados na Tabela 2.

Tabela 2 – *Hiperparâmetros utilizados para treinamento do modelo YOLO26m.*

Parâmetro	**Valor**
Épocas (`epochs`)	500
Resolução (`imgsz`)	640
Paciência (`patience`)	15
`lr0`	0,01
`lrf`	0,01
`momentum`	0,937
`weight_decay`	0,0005
`warmup_epochs`	3,0
`warmup_momentum`	0,8

Fonte: Silva *et al.* (2026).

Para avaliar o desempenho do modelo, utilizam-se métricas consolidadas na literatura para tarefas de detecção de objetos: Precisão (P), Revogação (R), Pontuação F1 ($F1S$) e a Precisão Média (AP), calculadas a partir da classificação

feita de Verdadeiros Positivos (VP), Falsos Positivos (FP), Verdadeiros Negativos (VN), Falsos Negativos (FN) e a Intersecção Sob União (IoU).

A Precisão (P), apresentada pela equação (1), mensura a proporção de detecções corretas em relação ao total de predições realizadas pelo modelo:

$$P = \frac{VP}{VP + FP} \tag{1}$$

A Revogação (R), calculada pela equação (2), mensura a capacidade do algoritmo em identificar corretamente todos os alvos reais presentes nas imagens, calculada pela razão entre os acertos e o total de objetos reais:

$$R = \frac{VP}{VP + FN} \tag{2}$$

Como costuma haver um *trade-off* entre essas duas métricas, o $F1S$ é utilizado como a média harmônica entre Precisão e Revogação, fornecendo uma medida única e balanceada do desempenho global:

$$F1S = 2 \cdot \frac{P \cdot R}{P + R} \tag{3}$$

A validação espacial e categórica das predições do modelo é quantificada por meio da Interseção sobre União (IoU), expressa pela Equação (4):

$$IoU = \frac{|\hat{B} \cap B_{gt}|}{|\hat{B} \cup B_{gt}|} \tag{4}$$

em que $\hat{B}$ representa a caixa delimitadora (*bounding box*) predita pelo modelo e B_{gt} denota a caixa delimitadora real (*ground truth*). A detecção é considerada um VP se o valor de IoU for maior ou igual a um limiar pré-definido τ_{IoU}.

Para abrandar o impacto de oscilações na curva de Precisão versus Revogação (P-R), calcula-se a Precisão Interpolada $p_{interp}(r)$ para um dado nível de revogação r, conforme a Equação (5):

$$p_{interp}(r) = \max_{\tilde{r} \geq r} p(\tilde{r}) \tag{5}$$

na qual $p(\tilde{r})$ é a precisão medida no nível de revogação $\tilde{r}$. A partir dessa interpolação, obtém-se a Precisão Média (AP) para uma classe c sob o limiar τ, que corresponde à área sob a curva P-R, calculada pela Equação (6):

$$AP_{c,\tau} = \int_0^1 p_{interp}(r)\, dr \tag{6}$$

Por fim, a métrica global mAP mensura a média das precisões médias (AP) integradas ao longo de todas as C classes e de um conjunto de limiares T, como formalizado na Equação (7):

$$mAP_{50-95} = \frac{1}{C} \sum_{c=1}^{C} \left(\frac{1}{10} \sum_{t \in T} AP_{c,t} \right) \tag{7}$$

3.2 Etapa II – Definição e Configuração do Hardware de *Edge AI*

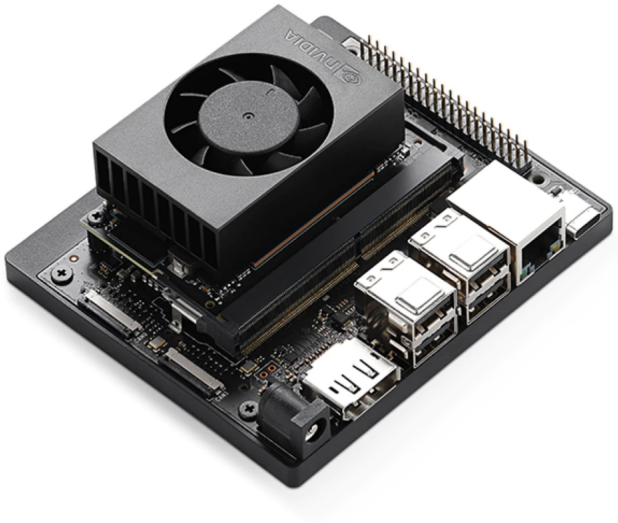
Esta etapa metodológica detalha a seleção, o dimensionamento e a configuração da plataforma de *Edge AI*, cuja finalidade é executar a inferência do modelo YOLO26m. A seguir, apresentam-se as especificações da arquitetura de hardware adotada, as ferramentas de compilação e os procedimentos de otimização aplicados para viabilizar a detecção eficiente e de baixo consumo energético em cenários de monitoramento de campo.

3.2.1 Definição do Hardware

A partir da contextualização feita no referencial teórico, o potencial do kit de desenvolvimento *NVIDIA Jetson Orin Nano* (8 GB) como o núcleo de processamento do sistema (NVIDIA Corporation, 2026), que pode ser observado na Figura 11, é selecionado como dispositivo *Edge AI* para o processamento do modelo YOLO26m.

O dispositivo apresenta um equilíbrio entre custo de aquisição, eficiência energética e capacidade de aceleração para algoritmos densos de visão computacional em borda. Equipado com uma GPU baseada na arquitetura NVIDIA Ampere dotada de 1.024 núcleos CUDA e 32 núcleos tensores (*Tensor Cores*), associada a uma CPU ARM Cortex-A78AE de 6 núcleos de 64 bits, o módulo entrega até 40 TOPS de desempenho de inferência em IA sob uma faixa de consumo térmico configurável de apenas 7 W a 15 W. Complementarmente, a placa-base (*carrier board*) do kit oferece interfaces essenciais para a integração dos nós em campo, incluindo barramentos M.2 Key M (PCIe Gen4 $\times 4$) para a instalação de unidades de armazenamento velozes em SSD NVMe, conector Gigabit Ethernet nativo para recepção direta do fluxo de vídeo da câmera via rede e conectividade serial para interfaceamento de comunicação externa (NVIDIA Corporation, 2026). Essa densidade computacional permite executar modelos convolucionais modernos em tempo real diretamente na torre, mantendo a autonomia necessária para operação sustentada por bancos de baterias e painéis fotovoltaicos sem comprometer a acurácia de detecção em campo.

Figura 11 – *Kit de Desenvolvimento Nvidia Jetson Orin Nano.*



Fonte: Adaptado de NVIDIA Corporation (2026).

3.2.2 Configuração de Hardware

Visando superar as limitações de largura de banda e durabilidade associadas aos cartões microSD convencionais, a estação embarcada foi configurada com um disco de estado sólido NVMe SSD M.2 de 256 GB, dedicado tanto ao armazenamento do sistema operacional quanto à hospedagem do ambiente de execução e dos modelos pré-treinados. O processo de preparação da plataforma iniciou-se com a gravação da imagem oficial do *JetPack 6.x* (baseado no Ubuntu 22.04 LTS) no SSD NVMe por meio da ferramenta *NVIDIA SDK Manager*, garantindo o particionamento direto no disco de alta velocidade e a configuração dos *bootloaders* do sistema. Em seguida, foram instalados e vinculados os drivers proprietários da arquitetura Ampere, as bibliotecas do CUDA *Toolkit* (versão 12.2), o cuDNN para aceleração de operações convolucionais e o TensorRT, assegurando a pilha de *software* necessária para a compilação e execução eficiente das inferências do modelo de detecção na ponta.

3.2.3 Integração da IA

A arquitetura de software desenvolvida para a plataforma Nvidia Jetson Orin Nano foi concebida de forma modular, articulando a execução da inferência de aprendizagem profunda a serviços de comunicação e transmissão de dados em tempo real. A detecção de objetos na ponta é gerenciada pelo *framework*

Ultralytics, encarregado do carregamento e da execução otimizada dos pesos do modelo YOLO26m ajustado e armazenado em arquivo *checkpoint* do PyTorch, que é o *framework* base da Ultralytics.

A camada de disponibilização de dados é estruturada sobre um servidor *web micro-framework* Flask, que expõe a interface de monitoramento e os *endpoints* de transmissão de vídeo. Para viabilizar o acesso remoto seguro ao fluxo do servidor sem a necessidade de IPs públicos fixos no ambiente de campo, utiliza-se a ferramenta Pyngrok, criando um túnel HTTP/HTTPS dinâmico sobre a porta local. O sistema de alertas e notificação imediata é gerenciado pela API do Twilio (via módulo *sending*), encarregada do envio automático de mensagens de emergência ao identificar focos de incêndio. Por fim, a gestão de chaves de API, senhas e parâmetros de rede é tratada pelo Python-Dotenv, isolando as variáveis de ambiente sigilosas do código-fonte principal e assegurando as boas práticas de segurança do sistema.

A aceleração computacional na plataforma Nvidia Jetson Orin Nano é viabilizada por sua GPU integrada baseada na arquitetura Ampere, composta por 1.024 núcleos CUDA e 32 Tensor Cores dedicados. No contexto de inferência de modelos de aprendizagem profunda como o YOLO26, a execução na GPU é essencial para realizar o processamento massivamente paralelo de convoluções e operações matriciais sobre os *frames* de vídeo em tempo real. Uma característica estrutural dessa plataforma é a Arquitetura de Memória Unificada (*Unified Memory Architecture* – UMA), na qual a CPU e a GPU compartilham a mesma memória RAM física (8 GB LPDDR5). Esse arranjo reduz significativamente a latência do sistema, uma vez que elimina a necessidade de copiar tensores de imagem entre a memória do sistema e a memória de vídeo dedicada (V_{RAM}) através de barramentos PCI Express.

Para alocar e otimizar o uso da GPU durante a execução da IA, o ambiente de *software* é configurado por meio da pilha de bibliotecas da Nvidia (*JetPack*). A comunicação direta com o hardware ocorre via *driver* proprietário e CUDA Toolkit, enquanto operações convolucionais complexas são aceleradas pela biblioteca cuDNN. Na camada de aplicação, o modelo é otimizado via TensorRT, que recompila o grafo da rede neuronal, aplicando técnicas de fusão de camadas, eliminação de operações mortas e quantização de precisão (conversão de ponto flutuante de 32 bits, $FP32$, para precisão reduzida de 16 bits, $FP16$, ou inteiros de 8 bits, $INT8$). Essa otimização permite que as rotinas do *framework* Ultralytics operem diretamente sobre o dispositivo `cuda:0`.

Visando assegurar o rendimento máximo da GPU sem restrições térmicas ou limitação de potência (*thermal throttling*), a configuração do sistema embarcado inclui o ajuste dos perfis de desempenho do sistema operacional. Por meio do

utilitário `nvpmodel`, a placa é definida para o modo de operação de maior consumo e capacidade computacional (MAXN ou 15 W), desativando os perfis de economia de energia. Adicionalmente, executa-se o *script* `jetson_clocks`, que fixa as frequências de clock da GPU, da CPU e dos barramentos de memória em seus valores nominais máximos, garantindo a estabilidade da taxa de FPS e a previsibilidade temporal durante a inferência na ponta.

3.3 Etapa III – Estabelecimento dos Meios de Comunicação

3.4 Etapa IV – Elaboração do Projeto Elétrico

O projeto elétrico do sistema foi elaborado com base nas diretrizes técnicas de Pinho e Galdino (2014) e em conformidade com as normas brasileiras (Associação Brasileira de Normas Técnicas, 2019) e (Associação Brasileira de Normas Técnicas, 2004). Embora o dispositivo de *Edge AI* do sistema tenha sido definido, o dimensionamento e a seleção dos equipamentos da fonte de alimentação demandam identificação precisa e caracterização elétrica de todos os dispositivos que compõem a carga do sistema. Esta etapa é direcionada ao planejamento da integração do protótipo para posteriormente realizar a montagem.

3.4.1 Seleção de Equipamentos

Para completar o sistema de monitoramento de focos de incêndio, além do dispositivo de borda e dos equipamentos que compõem a alimentação do sistema, deverá ser constituído de uma câmera dedicada que possua algumas das tecnologias identificadas na fundamentação teórica, um módulo de Internet 4G e um modem de internet para realizar o compartilhamento de rede.

Em relação ao dispositivo de câmera que será utilizado, com o propósito de assegurar a relação custo-benefício da solução desenvolvida, selecionou-se um equipamento de captura capaz de operar tanto no espectro visível quanto na faixa NIR em curtas distâncias operacionais. O sistema prioriza a detecção de incêndios durante o período diurno e em condições meteorológicas favoráveis, contornando a necessidade imediata de sensores térmicos de elevado custo financeiro.

A partir dessas premissas de viabilidade econômica e robustez de sensoriamento, é analisada a viabilidade da câmera PTZ *Intelbras VIP 5432 SD IR IA FT* (Intelbras, 2025). O dispositivo apresenta uma relação custo-benefício estratégica para o projeto ao dispensar matrizes térmicas de alto custo, entregando resolução

de 4 megapixels (2560 × 1440) a 30 quadros por segundo aliada a um conjunto óptico varifocal com zoom óptico motorizado de 32× (distância focal de 4,8 mm a 154 mm). Essa configuração óptica viabiliza a varredura panorâmica contínua em 360° (*pan*) associada à aproximação detalhada de alvos a longas distâncias, atendendo aos requisitos de cobertura territorial de grandes extensões de preservação ambiental. Para operar sob condições de baixa luminosidade e transição noturna, a câmera conta com sensor CMOS de alta sensibilidade com tecnologia *Starlight* e um sistema de iluminação ativa no espectro infravermelho próximo (NIR) composto por LEDs com alcance efetivo de até 150 metros (Intelbras, 2025). Por fim, o equipamento dispõe de carcaça metálica com grau de proteção IP67 e antivandalismo IK10, garantindo a integridade física do nó de captura contra intempéries climáticas severas, como chuvas torrenciais, poeira e variações bruscas de temperatura comuns ao ambiente de campo.

Figura 12 – *Câmera PTZ Intelbras VIP 5432 SD IR IA FT.*



Fonte: Intelbras (2025).

3.4.2 Projeto Elétrico

3.4.3 Dimensionamento

3.5 Etapa V – Montagem do Protótipo em Campo

3.6 Etapa VI – Desenvolvimento da Interface Web

Referências

Advexure. **Thermal vs IR: Understanding the spectrum of infrared technologies**. Irvine: [s.n.], 2023. Advexure News. Acesso em: 4 out. 2026. Disponível em: `https://advexure.com/blogs/news/thermal-vs-ir-understanding-the-spectrum-of-infrared-technologies`. 27

Agro Robotics. **Detecção de incêndios: Mosaico Carioca**. São Paulo: [s.n.], jul. 2022. Kickante. Responsável: Felipe da Agro Robotics. Acesso em: 12 out. 2026. Disponível em: `https://www.kickante.com.br/crowdfunding/deteccao-de-incendios-mosaico-carioca-01`. 20

Agência Nacional de Águas Brasil. **Conjuntura dos recursos hídricos no Brasil: regiões hidrográficas brasileiras — edição especial**. Brasília: [s.n.], 2015. Acesso em: 20 set. 2026. Disponível em: `https://www.snirh.gov.br/portal/snirh/centrais-de-conteudos/conjuntura-dos-recursos-hidricos/regioeshidrograficas2014.pdf`. 17

Associação Brasileira de Normas Técnicas. **ABNT NBR 5410: Instalações elétricas de baixa tensão**. Rio de Janeiro: [s.n.], 2004. Versão corrigida: 2008. 39

_____. **ABNT NBR 16690: Instalações elétricas de arranjos fotovoltaicos — Requisitos de projeto**. Rio de Janeiro: [s.n.], 2019. 39

BARMPOUTIS, Panagiotis *et al.* A review on early forest fire detection systems using optical remote sensing. **Sensors**, Basel, v. 20, n. 22, p. 1–26, 2020. Art. 6442. 18

BURTON, C. *et al.* State of wildfires 2025–2026. **Earth System Science Data Discussions**, 2026. Preprint, em avaliação. 17

Centro de Pesquisa e Desenvolvimento em Telecomunicações (CPQD). **Preservação de florestas é foco de projeto desenvolvido pelo CPQD com a agtech id2t na região do Cerrado**. Campinas: [s.n.], dez. 2025. CPQD Notícias. Acesso em:

13 set. 2026. Disponível em: https://www.cpqd.com.br/noticias/preservacao-de-florestas-e-foco-de-projeto-desenvolvido-pelo-cpqd-com-a-agtech-id2t-na-regiao-do-cerrado/. 20

DRIGGERS, Ronald G. *et al.* **Introduction to Infrared and Electro-Optical Systems**. 3. ed. Boston: Artech House, 2022. 27

FANTIN, Marcos. **Tecnologia ganha espaço no combate ao fogo no campo**. São Paulo: [s.n.], nov. 2025. Globo Rural. Tecnologia e Inovação. Acesso em: 13 set. 2026. Disponível em: https://globorural.globo.com/tecnologia-e-inovacao/noticia/2025/11/tecnologia-ganha-espaco-no-combate-ao-fogo-no-campo.ghtml. 21

GUARLADO, Lucas. **O que é Cerrado: características e biodiversidade**. jul. 2023. IPAM Amazônia. Acesso em: 20 set. 2026. Disponível em: https://ipam.org.br/o-que-e-cerrado-caracteristicas-biodiversidade-e-desmatamento/. 17

HARRYS, Mark. **Jetson TK1: Mobile embedded supercomputer brings CUDA everywhere**. 2014. NVIDIA Technical Blog. Acesso em: 2 out. 2026. Disponível em: https://developer.nvidia.com/blog/jetson-tk1-mobile-embedded-supercomputer-cuda-everywhere/. 25

HOWARD, Andrew G.; ZHU, Menglong; CHEN, Bo; KALENICHENKO, Dmitry; WANG, Weijun; WEYAND, Tobias; ANDREETTO, Marco; ADAM, Hartwig. MobileNets: Efficient convolutional neural networks for mobile vision applications. **arXiv preprint arXiv:1704.04861**, p. 1–9, 2017. Acesso em: 2 out. 2026. Disponível em: https://arxiv.org/abs/1704.04861. 23

IBGE – Instituto Brasileiro de Geografia e Estatística. **Síntese descrição biomas**. Rio de Janeiro: [s.n.], 2009. Data aproximada: [2009?]. Disponível em: https://geoftp.ibge.gov.br/informacoes_ambientais/estudos_ambientais/biomas/documentos/Sintese_Descricao_Biomas.pdf. 17

Instituto Socioambiental (ISA). **Unidades de Conservação no Brasil: Mapa**. São Paulo: [s.n.], s.d. ISA. Acesso em: 11 out. 2026. Disponível em: https://uc.socioambiental.org/mapa. 17

Intel Corporation. **Intel® Movidius™ Myriad™ X VPU: Product Brief**. Santa Clara: [s.n.], 2018. Disponível em: https://www.intel.com/content/dam/www/public/us/en/documents/product-briefs/myriad-x-product-brief.pdf. 26

Intelbras. **VIP 5432 SD IR IA FT: Câmera Speed Dome IP com inteligência artificial e zoom óptico de 32x. Ficha técnica**. São José: [s.n.], dez. 2025. Disponível em: https://backend.intelbras.com/sites/default/files/2025-12/Datasheet%20V3%20-%20VIP%205432%20SD%20IR%20IA%20FT_1.pdf. 39, 40

JN Fogo – Câmeras Amolar. **JN Fogo Câmeras Amolar**. out. 2023. YouTube. Produção: umgrauemeio. 1 vídeo (2 min 17 seg). Acesso em: 13 set. 2026. Disponível em: https://www.youtube.com/watch?v=ksH9mUBCQnY. 20

JOCHER, Glenn; QIU, Jing; LIU, Mengyu; LYU, Shuai; AKYON, Fatih Cagatay; KALFAOGLU, Muhammet Esat. **Ultralytics YOLO26: unified real-time end-to-end vision models**. 2026. ArXiv:2606.03748 [cs.CV]. 32

KHALIFEH, A. *et al.* A machine learning-based early forest fire detection system utilizing vision and sensors' fusion technologies. *In*: **Proceedings of the IEEE Middle East and North Africa Communications Conference (MENACOMM)**. Amman: IEEE, 2022. p. 229–234. 19

KRIZHEVSKY, Alex; SUTSKEVER, Ilya; HINTON, Geoffrey E. ImageNet classification with deep convolutional neural networks. *In*: PEREIRA, F. *et al.* (Ed.). **Advances in Neural Information Processing Systems 25**. Red Hook: Curran Associates, 2012. p. 1097–1105. Disponível em: https://proceedings.neurips.cc/paper_files/paper/2012/file/c399862d3b9d6b76c8436e924a68c45b-Paper.pdf. 23

LIN, Tsung-Yi *et al.* **Microsoft COCO: Common Objects in Context**. 2014. ArXiv preprint. Acesso em: 25 out. 2026. Disponível em: https://doi.org/10.48550/arXiv.1405.0312. 33

LIU, Wei *et al.* SSD: Single shot MultiBox detector. *In*: **Proceedings of the European Conference on Computer Vision (ECCV)**. Amsterdã: Springer, 2016. (Lecture Notes in Computer Science), p. 21–37. 22, 24

MapBiomas. **RAD 2025: Relatório Anual do Desmatamento no Brasil**. São Paulo: [s.n.], maio 2026. Acesso em: 20 set. 2026. Disponível em: https://alerta.mapbiomas.org. 17

_____. **RAF 2025: Relatório Anual do Fogo no Brasil**. São Paulo: [s.n.], 2026. Acesso em: 20 set. 2026. Disponível em: https://alerta.mapbiomas.org. 17

MATAMOROS, E. A. Castillo; MONTALVáN, R. S. Chalco; MARTíNEZ, S. R. González. Forest fire detection and alert system based on image processing and AI. **Revista Tecnológica - ESPOL**, v. 37, n. E1, p. 88–111, 2025. 19

MINHA, Amerzish. **Forest Fire, Smoke, and Non-Fire Image Dataset**. 2023. Kaggle. Acesso em: 20 set. 2026. Disponível em: https://www.kaggle.com/datasets/amerzishminha/forest-fire-smoke-and-non-fire-image-dataset. 33

NVIDIA Corporation. **Jetson Orin Nano Developer Kit User Guide: Hardware Layout**. Santa Clara, 2026. Acesso em: 4 out. 2026. Disponível em: https://docs.nvidia.com/jetson/orin-nano-devkit/user-guide/latest/hardware_layout.html. 36, 37

PEREIRA, Enio Bueno *et al.* **Atlas brasileiro de energia solar**. 2. ed. São José dos Campos: INPE, 2017. 88 p. Acesso em: 4 out. 2026. Disponível em: http://mtc-m21b.sid.inpe.br/col/sid.inpe.br/mtc-m21b/2017/08.15.18.20/doc/Atlas_Brasileiro_Energia_Solar_2a_Edicao_rev-01-compactado.pdf. 29

PINHO, João Tavares; GALDINO, Marco Antonio (Ed.). **Manual de Engenharia para Sistemas Fotovoltaicos**. Rio de Janeiro: CEPEL / CRESESB, 2014. 29, 39

Raspberry Pi Foundation. **Raspberry Pi 1 Model B+**. Cambridge: [s.n.], s.d. Raspberry Pi Ltd. Acesso em: 2 out. 2026. Disponível em: https://www.raspberrypi.com/products/raspberry-pi-1-model-b-plus/. 25

REDMON, Joseph *et al.* You only look once: unified, real-time object detection. *In*: **Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)**. Las Vegas: IEEE, 2016. p. 779–788. 22

REN, Shaoqing *et al.* Faster R-CNN: Towards real-time object detection with region proposal networks. *In*: **Advances in Neural Information Processing Systems (NeurIPS)**. Montreal: Curran Associates, 2015. v. 28, p. 91–99. 22, 23, 24

SILVA, Rhuan Messias; JúNIOR, Carlos Roberto da Silveira; BEZERRA, Carlos Daniel Sousa; SIQUEIRA, Cleuber Marques. **Sistema inteligente de monitoramento de focos de incêndio para parques estaduais e áreas de preservação ambiental**. Goiânia: [s.n.], 2026. Relatório não publicado. 33, 34

VASCONCELOS, Rafael Miranda; FREITAS, Paulo André Moreira De; LAZZARINI, Gustavo Maximiano Junqueira. Análise da incidência de focos de calor em unidades de conservação, terras indígenas e quilombolas do Estado de Goiás entre 2008 e 2017. **Biodiversidade Brasileira**, v. 9, n. 1, 2019. 18

VERSIANE, Daniela. **Cerca de 450 mil hectares do Cerrado goiano foram queimados em 2024, segundo relatório**. Goiânia: [s.n.], jul.

2025. CBN Goiânia. Tarde CBN. Acesso em: 6 set. 2026. Disponível em: https://cbngoiania.com.br/tarde-cbn/cerca-de-450-mil-hectares-do-cerrado-goiano-foram-queimados-em-2024-segundo-relatorio-1.3288012. 18

ZHAO, M.; YE, R.-J.; CHEN, S.-T.; CHEN, Y.-C.; CHEN, Z.-Y. Realization of forest Internet of Things using wireless network communication technology of low-power wide-area network. **Sensors**, v. 23, n. 10, 2023. Art. 4809. 20

Apêndice A – Lista de palavras-chave em português para o pacote **algorithm2e**

```
\Entrada{Entrada}
\Saida{Saída}
\Dados{Dados}
\Resultado{Resultado}
\Ate
\KwRetorna{[valor]}
\Retorna{[valor]}
\Iniciob{bloco interior}
\eSe{cindição}{bloco então}{bloco senão}
\Se{condição}{bloco então}
\uSe{condição}{boco então sem término}
\lSe{condição}{linha de texto do então}
\Senao{bloco senão}
\uSenao{bloco senão sem senão}
\lSenao{linha de texto do senão}
\SenaoSe{condição}{bloco senãose}
\uSenaoSe{condição}{bloco senãose sem término}
\lSenaoSe{condição}{linha de texto do senãose}
\Selec{condição}{bloco da seleção}
\Caso{um caso}{bloco do caso}
\uCaso{um caso}{bloco do caso sem término}
\lCaso{um caso}{linha do caso}
\Outro{bloco caso contrário}
\lOutro{linha do caso contrário}
\Para{condição}{texto do laço de repetição}
\lPara{condição}{linha do laço de repetição}
\ParaPar{condição}{texto do laço de repetição}
\lParaPar{condição}{linha do laço de repetição}
\ParaCada{condição}{texto do laço de repetição}
\lParaCada{condição}{linha do laço de repetição}
\ParaTodo{condição}{texto do laço de repetição}
\lParaTodo{condição}{linha do laço de repetição}
```

```
\Enqto{stop condição}{texto do laço de repetição}
\lEnqto{stop condição}{texto do laço de repetição}
\Repita{stop condição}{texto do laço de repetição}
\lRepita{stop condição}{linha do laço de repetição}
```

Anexo A – Exemplo de anexo

Conteúdo do anexo.